

AI360

**ПРЕДСТАВЛЕНИЕ РЕЗУЛЬТАТОВ
РАБОТЫ КОМАНДЫ НА ПРОЕКТНОЙ ШКОЛЕ**

Данная презентация является примером структурирования и оформления результатов.
Она может быть дополнена или скорректирована командой в случае необходимости,
Москва, 2026

КТО МЫ

AI360: Представление
результатов
работы команды
на Проектной школе


Наименование тематики Голосовой ИИ помощник для
врача

Участники



Александрова Софья

Университет Иннополис



Дана
Трошина

Университет Иннополис



Анастасия Янко

Высшая Школа Экономика




Вишован Дмитрий

Университет Иннополис

Ментор

AI360: Представление
результатов
работы команды
на Проектной школе



Роман Лисов

Руководитель службы
разработки и ML Яндекс

Врач тратит много
времени на работу в ПК?



Точно да

Вероятно

Скорее нет

Точно нет

Врач тратит много времени на работу в ПК?




Продуктовые задачи

AI360: Представление
результатов
работы команды
на Проектной школе

Голосовой ассистент с доверенной базой знаний.

- Все данные загружены из **проверенных источников**
- Врач задает **вопрос голосом** — система ищет ответ в секунды.
- Больше **не нужно перепроверять** информацию



Концепция RAG

AI360: Представление
результатов
работы команды
на Проектной школе

RAG (Retrieval-Augmented Generation / Генерация, дополненная поиском) — это архитектурный подход в области искусственного интеллекта, при котором большая языковая модель (LLM) генерирует ответ на запрос пользователя, основываясь не только на своих скрытых весах («памяти»), но и на внешних, авторитетных и динамически обновляемых данных, извлеченных из изолированной базы знаний в режиме реального времени.

Запрос

Retrieval


**Augmentati
on**

**Generatio
n**

База знаний



ML-pipeline



Метрики качества

AI360: Представление
результатов
работы команды
на Проектной школе

Для оценки качества было проведено сравнение двух систем на выборке из **40 медицинских запросов**.


Оценка выполнялась с использованием подхода **LLM-as-a-Judge**, при котором языковая модель сравнивала ответы YandexGPT-8B без и с RAG по качеству и выбирала наиболее предпочтительный ответ.

Результаты сравнения:

- Наша RAG-система — **34 победы**
- Ничья — **5 случаев**
- YandexGPT без RAG-системы — **1 победа**

Итоговые метрики:

- Win Rate: **85%**
- Pairwise Preference Score: **91.25%**
- Преимущество над baseline: **×34**



Слабые места и зоны роста

AI360: Представление
результатов
работы команды
на Проектной школе

Ограниченные ресурсы сервера

Текущая конфигурация — 4 ядра, 8 ГБ ОЗУ.

Мощности не хватает для одновременной работы индексации, поиска и генерации, особенно на пиковых нагрузках.

Проблемы поиска в RAG-системе

Этап реранкинга, использование линейного векторного поиска, этап трансформации запросов, большой размер контекста.



Шаги развития

AI360: Представление
результатов
работы команды
на Проектной школе

Переход на приближенный поиск (ANN): Заменить в FAISS базовый точный индекс IndexFlatIP на графовый индекс **HNSW** (Hierarchical Navigable Small World). Это ускорит поиск в разы при сохранении точности на уровне 99%.

Квантование моделей (Quantization): Сжать веса моделей эмбеддингов и реранкера из формата Float32 в Int8 или FP16. Это снизит требования к оперативной памяти и ускорит инференс на CPU.

Гибридный поиск (Hybrid Retrieval): Реализовать параллельный поиск: векторный (семантический) + классический текстовый (алгоритм BM25). Слияние их результатов (через Reciprocal Rank Fusion).

Развертывание контурного мониторинга (Observability)

Подключить системы логирования и трассировки. Для того чтобы в реальном времени видеть, на каком именно система тратит больше всего времени и где происходят сбои в JSON-форматировании.





medhelper.2bd.net



MedAI Assistant



Здравствуйте, коллега. Я MedAI — ваш ассистент для клинических вопросов. Чем могу помочь?



Опишите клинический случай...



Вопросы?

AI360: Представление
результатов
работы команды
на Проектной школе

GitHub



Продукт




Architecture



[https:// github.com/nastyaya10/LLM_Doctor-s_assistant#](https://github.com/nastyaya10/LLM_Doctor-s_assistant#)

<https://medhelper.2bd.net>

https://excalidraw.com/#room=053e0c902f988ae46d7b,qn_aVTNjtCwqb5LUD6dfzw



Яндекс

СБЕР



УНИВЕРСИТЕТ
ИННОПОЛИС

МФТИ

ИТМО



Спасибо за внимание!